

Mineração de Textos em Diários Oficiais: Uma Abordagem de Ciência de Dados para Auditoria de Contratos Públicos

Vitor Fialho

24 de Junho de 2026

Resumo

A transparência governamental é um pilar da gestão pública, mas o volume massivo de publicações em Diários Oficiais torna a auditoria manual inviável. Este projeto tem como objetivo central a classificação e visualização do Ciclo de Vida e Eixo Temático das Licitações e Termos Aditivos, com foco especial na identificação de contratos que estouraram o orçamento inicial. Através da aplicação de técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning, buscou-se automatizar a extração de dados financeiros não estruturados para a construção de um painel de Business Intelligence analítico e escalável.

1 Introdução e Definição do Problema

O controle de gastos na esfera municipal depende intrinsecamente da auditoria de contratos e suas repactuações financeiras. Contudo, as informações repousam em formatos não estruturados, espalhadas por diários oficiais redigidos sem padronização semântica unificada. O objetivo deste trabalho consiste em minerar e classificar o escopo e o eixo temático de licitações e aditivos. A hipótese principal é que, mediante a vetorização textual e classificação por algoritmos de aprendizado de máquina, torna-se possível não apenas identificar a natureza do documento, mas extrair relacionamentos financeiros capazes de apontar desvios ou estouros de orçamento.

2 Trabalhos relacionados

A classificação automática de licitações em diários oficiais tem sido abordada por meio de diversas estratégias de aprendizado de máquina, variando de abordagens clássicas a modelos baseados em transformadores. O uso de modelos pré-treinados, como o BERTimbau, demonstrou alta eficácia, alcançando 96% de precisão na classificação de despesas públicas relacionadas à COVID-19[Santos e Moura 2023]. Além disso, o desenvolvimento de modelos especializados, como o GovBERT-BR, visa capturar as nuances da linguagem governamental brasileira para otimizar a gestão de processos licitatórios[Silva et al. 2024].

Pesquisas recentes também exploram a combinação de diferentes representações textuais para melhorar o desempenho dos classificadores. As estratégias adotadas incluem:

- Abordagens híbridas: Combinação de embeddings semânticos (frequentistas, estáticos e contextuais) com técnicas de stacking e transformadores[Constantino et al. 2023].
- Aprendizagem ativa: Utilizada para reduzir o esforço de rotulagem manual, permitindo a classificação semântica de seções de interesse, como licitações e leis, com uma precisão global de 85%[Constantino et al. 2023].
- Supervisão fraca: Empregada no projeto BidCorpus, que utiliza técnicas de rotulagem automática e modelos baseados em BERT para processar milhares de documentos de licitações, superando a ineficiência da análise manual[Lima et al. 2024].

3 Arquitetura de Coleta e Engenharia de Dados

A fase de aquisição de dados exigiu contornos arquitetônicos robustos. Inicialmente, o projeto buscou realizar chamadas massivas à API do projeto de código aberto "Meu Querido Diário"[Open Knowledge Brasil 2026], porém a operação foi bloqueada por restrições de infraestrutura cloud.

A solução técnica adotada foi a clonagem do repositório oficial e a construção de um motor de raspagem distribuído utilizando a biblioteca *Scrapy*[Scrapy 2026], gerando um banco de dados independente. O mapeamento priorizou estados com grande número de municípios disponíveis no projeto, destacando-se, Bahia (74) e Minas Gerais (21). O pipeline procedeu com a busca e extração dos códigos IBGE de 371 municípios, implementando uma rotina de normalização sintática para garantir o pareamento correto com a base oficial do IBGE.

Nesta primeira etapa de prospecção, os robôs extraíram metadados e URLs, resultando em um universo mapeado de 50.202 diários oficiais, distribuídos em 175 cidades. Para evitar corrupção de dados — um problema real na serialização de textos jurídicos contendo vírgulas em seus parágrafos —, a arquitetura padronizou o uso estrito de delimitadores de ponto e vírgula nos pipelines de persistência em disco.

4 Amostragem Estratificada e Preparação Textual

Devido às restrições de processamento em memória e à inviabilidade de treinar o modelo preditivo utilizando a base total logo na primeira iteração, definiu-se a utilização de uma amostragem estratificada proporcional. A extração inicial abarcou um orçamento global de 500 documentos em formato PDF, posteriormente expandido para 5.000 PDFs, garantindo que todas as cidades tivessem representatividade na amostra de treinamento.

A vetorização dos textos foi realizada através do método *Term Frequency-Inverse Document Frequency* (TF-IDF)[Sparck Jones 1972]. O TF-IDF reflete a importância de uma palavra em um documento em relação ao corpus inteiro, penalizando termos genéricos (como artigos e preposições jurídicas) e destacando jargões cruciais (como "prorrogação", "acréscimo", "pregão").

A análise exploratória dessa amostra vetorizada revelou a principal anomalia estatística inerente à administração pública: um severo desbalanceamento de classes. A distribuição dos parágrafos rotulados apresentou os seguintes volumes:

- **Outros:** 485.195 instâncias.
- **Licitação:** 7.926 instâncias.

- **Aditivo:** 2.983 instâncias.

5 Treinamento e Otimização: A Matemática do SMOTE

O desenvolvimento do motor de classificação se iniciou com o estabelecimento de um *Baseline* algorítmico suportado pelo modelo Random Forest[Breiman 2001]. Embora tenha alcançado acurácia geral alta em virtude do volume esmagador da classe "Outros", a performance no reconhecimento de "Aditivos"(a classe minoritária de maior interesse para auditoria) foi insatisfatória, apresentando um Recall de 0.772 e dezenas de falsos negativos.

Tabela 1: Relatório de Classificação - Baseline (Random Forest)

Classe	Precision	Recall	F1-Score	Support
Aditivo	0.97	0.77	0.86	597
Licitação	0.93	0.86	0.89	1585
Outros	1.00	1.00	1.00	97039
Accuracy			1.00	99221
Macro Avg	0.96	0.88	0.92	99221
Weighted Avg	1.00	1.00	1.00	99221

Para solucionar essa assimetria, implementou-se a técnica *Synthetic Minority Over-sampling Technique* (SMOTE)[Chawla et al. 2002]. Diferente de técnicas de *Oversampling* simples (que apenas duplicam registros minoritários e aumentam o risco de sobreajuste ou *overfitting*), o SMOTE atua no espaço dimensional das features, criando novas instâncias sintéticas a partir da interpolação matemática entre uma amostra minoritária real e seus k -vizinhos mais próximos (k-Nearest Neighbors).

Formalmente, seja x_i um vetor no espaço de características pertencente à classe "Aditivo", e x_{zi} um dos seus k vizinhos da mesma classe. Uma nova instância sintética x_{new} é gerada pela equação:

$$x_{new} = x_i + \lambda \times (x_{zi} - x_i) \quad (1)$$

Onde λ é um vetor de valores aleatórios uniformemente distribuídos no intervalo $[0, 1]$.

Essa propriedade permite que a fronteira de decisão do modelo preditivo se expanda rumo à classe majoritária, reduzindo a probabilidade de um aditivo camuflado ser classificado como "Outro".

Uma "Arena de Modelos" foi instaurada para contrapor diferentes técnicas de balanceamento (Under e Oversampling) aos algoritmos Random Forest, XGBoost e Regressão Logística.

Tabela 2: Resultado da Arena de Modelos

Modelo	Balanceamento	Acurácia Global	Recall Aditivo	F1 Licitação
Regressão Logística	Baseline	0.9835	0.9748	0.7225
Random Forest	Baseline	0.9952	0.7721	0.8920
XGBoost	Baseline	0.9937	0.8467	0.8743
Random Forest	Undersampling	0.9617	0.9916	0.5646
Regressão Logística	Undersampling	0.9647	0.9849	0.5607
XGBoost	Undersampling	0.9881	0.9933	0.7703
Regressão Logística	SMOTE	0.9851	0.7397	0.9715
Random Forest	SMOTE	0.9962	0.9148	0.8927
XGBoost	SMOTE	0.9966	0.9832	0.9239

O XGBoost acompanhado do SMOTE [Chen e Guestrin 2016, Chawla et al. 2002] consagrou-se como a arquitetura ideal, combinando a capacidade de aprendizado por *Gradient Boosting* de árvores com um espaço vetorial simétrico, culminando em um F1-Score de 0.93 para Aditivos e 0.92 para Licitações, limitando as perdas sistêmicas.




Figura 1: Matriz de Confusão: XGBoost com técnica de SMOTE.

Tabela 3: Relatório de Classificação Oficial - XGBoost + SMOTE

Classe	Precision	Recall	F1-Score	Support
Aditivo	0.89	0.98	0.93	597
Licitação	0.88	0.97	0.92	1585
Outros	1.00	1.00	1.00	97039
Accuracy			1.00	99221
Macro Avg	0.92	0.98	0.95	99221
Weighted Avg	1.00	1.00	1.00	99221

6 Arquitetura Data Lake e Extração de Informação (RegEx)

Identificado o parágrafo de interesse pelo modelo de Machine Learning, o próximo desafio tecnológico foi a Extração de Informação. O algoritmo recorreu a Expressões Regulares (RegEx) para isolar características operacionais: a captura de padrões de moeda convertidos em número decimal (R\$) e a extração do número do processo que serviria como ID para ligar a tabela de aditivos com a de licitações.

Para garantir a qualidade dos dados da chave relacional, a RegEx foi aprimorada para evitar falsos positivos de calendário (ex.: captura do texto "datado de 28/02"), impondo o padrão estrito de dígitos sequenciais seguidos de quatro dígitos do ano formatado ("20\d{2}"). Foi incluída a captura da área temática através de palavras-chave, visando permitir gráficos detalhados no BI[[Microsoft 2026](#)].

Ao transpor essa solução de uma amostra controlada para um universo de mais de 24 mil PDFs (majoritariamente de municípios do estado da Bahia), tornou-se imprescindível a construção de um orquestrador operando num paradigma estrutural próximo a um *Data Lake*. Tentativas nativas de processar e persistir *dataframes* completos dessa magnitude em arquivos monolíticos culminam, invariavelmente, no estouro da memória RAM.

Adotou-se o formato Apache Parquet, altamente otimizado por sua estrutura colunar e compressão algorítmica. O extrator operou no conceito de partições: a cada "N" documentos extraídos, a memória era despejada em um arquivo físico particionado, utilizando rotinas explícitas de liberação pelo coletor de lixo do Python (*Garbage Collector*).

Posteriormente, o XGBoost consumiu esse lago de partições através de leitura em lotes iterativos (Chunks). O resultado dessa engenharia de dados foi uma base enxuta com 5.091 licitações e aditivos reais, consolidando as colunas 'classe_alvo', 'valor_R\$', 'municipio', 'data' e a 'chave_unica'.

7 Visualização Analítica e Business Intelligence

A integridade dos dados modelados permitiu a construção de um ambiente de Business Intelligence (BI). A base limpa expôs a existência de "Aditivos Órfãos"— repactuações milionárias em que o contrato principal originário foi publicado antes da janela de processamento e mineração suportada pelo projeto.

Para blindar o painel, a narrativa analítica foi desmembrada em duas camadas visuais dinâmicas. Na primeira, observou-se o impacto global, ignorando relacionamentos para

sumarizar a presença geral de movimentações. A segunda, focada no *Cálculo Confiável*, introduziu *Data Analysis Expressions* (DAX) sob iteradores rigorosos ('SUMX'), descartando contratos sem bases atreladas e alertando para repactuações superiores ao teto limítrofe usual na administração pública (> 50%).

A configuração resultou na entrega de um Dashboard analítico e arrojado (Dark Mode), contando com painéis com cartões (Cards), mapas de bolhas para densidade estadual, gráficos de dispersão entre bases contratuais e gráficos de barras com o ranking de repactuações por municípios.

8 Visualizações do Painel de *Business Intelligence*

A consolidação dos dados minerados permitiu a construção de um painel gerencial dinâmico. Abaixo, são apresentadas as principais visualizações desenvolvidas no Microsoft Power BI [Microsoft 2026] para a auditoria dos contratos públicos:



Figura 2: Visão Macro (KPIs): Cartões dinâmicos demonstrando o volume base contratado, o impacto financeiro dos aditivos e a taxa média de acréscimo.




Figura 3: Visão Geográfica: Mapa de bolhas geolocalizado evidenciando a distribuição e o valor total do aditivo cruzado com o percentual sobre o valor da licitação.




Figura 4: Visão Analítica: Gráfico de dispersão destacando a relação entre o valor das licitações e seus aditivos, ideal para a identificação de discrepâncias e anomalias contratuais.



Figura 5: Ranqueamento Executivo: Gráfico de barras apresentando os municípios com os maiores ofensores absolutos (valor total dos aditivos).



Figura 6: Ranqueamento Executivo: Gráfico de barras apresentando os municípios com os maiores ofensores relativos (percentual de repactuação).

9 Detalhamento dos Municípios Ofensores (Maior Percentual de Aditivos)

A análise do painel evidenciou que três municípios do estado da Bahia concentraram os maiores ofensores relativos, apresentando taxas de repactuação contratual superiores a 40% em relação ao valor das licitações originais. Abaixo, detalha-se o perfil socioeconômico e político dessas localidades em 2025:

1. Barreiras (BA) – 48,10% de Aditivos

- **Prefeito (Gestão iniciada em 2025):** Otoniel Teixeira (UNIÃO).
- **População:** 159.743 habitantes (Censo IBGE 2022).
- **Contexto Socioeconômico:** Conhecida como a "Capital do Oeste", Barreiras é o principal polo econômico, comercial e educacional da região Oeste da Bahia. A cidade possui um Produto Interno Bruto (PIB) expressivo, impulsionado fortemente pelo agronegócio (soja e algodão). Por ser um município de grande porte orçamentário, uma taxa de **48,10%** em aditivos representa um volume financeiro absoluto altíssimo. Isso sugere que grandes obras de infraestrutura regional ou contratos de serviços contínuos estão sofrendo repactuações massivas, o que é um ponto crítico para auditoria.

2. Brotas de Macaúbas (BA) – 46,43% de Aditivos

- **Prefeito (Gestão iniciada em 2025):** Dr. Kleber (PSD).
- **População:** 11.765 habitantes (Censo IBGE 2022).
- **Contexto Socioeconômico:** Localizada na região da Chapada Diamantina, Brotas de Macaúbas apresenta um cenário diametralmente oposto a Barreiras. Trata-se de um município de pequeno porte, com uma baixíssima densidade demográfica (aproximadamente 5 habitantes por km²). O fato de uma prefeitura com arrecadação e capacidade operacional tão reduzidas apresentar **46,43%** de taxa de aditivos é um forte indicativo de graves falhas na fase de planejamento das licitações (orçamentos base irreais) ou dependência extrema de aditivos emergenciais para garantir o funcionamento da máquina pública.

3. Itamaraju (BA) – 41,90% de Aditivos

- **Prefeito (Gestão iniciada em 2025):** Jorge Almeida (PSDB).
- **População:** 59.603 habitantes (Censo IBGE 2022).
- **Contexto Socioeconômico:** Situada no Extremo Sul baiano, Itamaraju é uma cidade de médio porte com economia historicamente ligada à agropecuária (com forte presença na cultura do cacau, café e pecuária de corte). O percentual de **41,90%** aponta para um cenário de reajustes constantes. Em cidades dessa faixa populacional e perfil econômico, os estouros de orçamento costumam estar atrelados a contratos de manutenção de estradas vicinais (escoamento de safra) e serviços básicos de saúde e educação rural.

10 Conclusão

A união estruturada de engenharia de dados, modelos de machine learning e visualização por Business Intelligence se provou eficaz na quebra do paradigma da "Caixa Preta" de documentos públicos. O emprego de um Data Lake escalável e a correção de classes com SMOTE culminaram em um pipeline de transparência passível de generalização. Os resultados atestam a viabilidade técnica de automatizar a auditoria civil de bilhões de reais do orçamento municipal, substituindo a leitura massiva manual por estratégias preditivas e analíticas ágeis, convertendo repositórios passivos de diários oficiais em observatórios fiscais ativos.

Referências

- [Breiman 2001] Breiman, L. (2001). Random forests. *Machine learning*, 45(1):5–32.
- [Chawla et al. 2002] Chawla, N. V., Bowyer, K. W., Hall, L. O., e Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16:321–357.
- [Chen e Guestrin 2016] Chen, T. e Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 785–794.

- [Microsoft 2026] Microsoft (2026). Microsoft Power BI: Business Intelligence and Data Visualization. Disponível em: <<https://powerbi.microsoft.com/>>. Acesso em: 23 jun. 2026.
- [Open Knowledge Brasil 2026] Open Knowledge Brasil (2026). Projeto Querido Diário: Diários Oficiais abertos e acessíveis. Disponível em: <<https://queridodiario.ok.org.br/>>. Acesso em: 23 jun. 2026.
- [Pedregosa et al. 2011] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., e Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of machine learning research*, 12:2825–2830.
- [Scrapy 2026] Scrapy Developers (2026). Scrapy: A Fast and Powerful Scraping and Web Crawling Framework. Disponível em: <<https://scrapy.org/>>. Acesso em: 23 jun. 2026.
- [Sparck Jones 1972] Sparck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*, 28(1):11–21.
- [Santos e Moura 2023] Santos, P. V. S. e Moura, R. S. (2023). Automatic Classification of Public Expenses in the Fight against COVID-19: A Case Study of TCE/PI. DOI: 10.1145/3592813.3592909.
- [Silva et al. 2024] Silva, M. O., Oliveira, G. P., Costa, L. L., e Pappa, G. L. (2024). GovBERT-BR: A BERT-based language model for Brazilian Portuguese governmental data. DOI: 10.1007/978-3-031-79032-4_2.
- [Constantino et al. 2023] Constantino, K. et al. (2023). Using Active Learning for Segmentation and Semantic Classification of Legal Acts Extracted from Official Diaries. *Journal of Information and Data Management*. DOI: 10.5753/jidm.2023.3181.
- [Lima et al. 2024] Lima, W., Silva, V., Silva, J. C. O., Lira, R., e Paiva, A. C. de (2024). BidCorpus: A Multifaceted Learning Dataset for Public Procurement. *Data in Brief*, 58:111202. DOI: 10.1016/j.dib.2024.111202.